HƯỚNG DẪN THỰC HIỆN ĐỒ ÁN

DÓNG HÀNG HÁN-VIỆT

1. Mục đích của tài liệu

Tài liệu này hướng dẫn các nhóm sinh viên thực hiện đồ án xây dựng dữ liệu song ngữ Hán – Việt ở cấp câu/đoạn. Mỗi nhóm gồm tối đa 4 thành viên. Mỗi thành viên phải hoàn thành tối thiểu 2000 cặp dóng hàng hợp lệ, tương đương tối thiểu 8.000 cặp hợp lệ cho một nhóm (đối với các tài liệu đầu vào dạng ảnh/pdf scan cần ocr), và tối thiểu 3000 cặp dóng hàng hợp lệ, tương đương tối thiểu 12.000 cặp hợp lệ cho một nhóm 4 thành viên (đối với các tài liệu đầu vào dạng text/có thể trích xuất text trực tiếp).
Nhóm được quyền tự chọn công cụ, tự xây dựng quy trình hoặc đề xuất phương pháp khác. Công cụ chỉ là phương tiện; sản phẩm cuối phải tuân thủ định dạng bàn giao và đạt tiêu chí chất lượng chung trong tài liệu này.

2. Sản phẩm cuối cùng cần bàn giao

Mỗi nhóm nộp một thư mục có cấu trúc khuyến nghị:

```
<MA_DE_TAI>_<MA_TAC_PHAM>/
├── 01_nguon/
│   ├── han/
│   └── viet/
├── 02_ocr_tho/
│   ├── han/
│   └── viet/
├── 03_text_sach/
│   ├── han.txt
│   └── viet.txt
├── 04_dong_hang/
│   ├── <MA_TAC_PHAM>_parallel.tsv
│   └── <MA_TAC_PHAM>_parallel.xlsx
```

Tối thiểu phải có:

1. File kết quả dóng hàng dạng TSV.
2. File kết quả dóng hàng dạng Excel (`.xlsx`).
3. File văn bản Hán và Việt đã làm sạch.
4. Báo cáo số lượng cặp, số dòng Hán, số dòng Việt và kết quả tự kiểm tra.
5. Thông tin nguồn tài liệu và công cụ xử lý.

3. Định dạng bắt buộc của file dóng hàng

Mỗi dòng chứa đúng một cặp Hán – Việt, phân cách bằng một ký tự tab:

```
<CÂU_HÁN><TAB><CÂU_VIỆT>
```

Ví dụ:

```
古南交，周號越裳。\tĐất Nam Giao xưa, nhà Chu gọi là Việt Thường.
```

Yêu cầu kỹ thuật:

- Mỗi cặp nằm trên một dòng vật lý.
- Không dùng nhiều dấu cách thay cho tab.
- Không để tab hoặc xuống dòng bên trong một vế.
- Bắt buộc nộp đồng thời `.tsv` và `.xlsx`; nội dung hai file phải giống nhau.
- Tên file khuyến nghị: `<MA_TAC_PHAM>_parallel.tsv`.

File Excel có một sheet tên DONG_HANG, gồm đúng hai cột:

Hán	Việt
古南交，周號越裳。	Đất Nam Giao xưa, nhà Chu gọi là Việt Thường.

Yêu cầu đối với Excel:

- Hàng đầu tiên là tiêu đề `Hán` và `Việt`.

- Từ hàng thứ hai, mỗi hàng tương ứng đúng một dòng trong TSV.
- Không gộp ô, không chèn dòng trống và không đặt công thức trong hai cột dữ liệu.
- Không thêm số thứ tự vào giữa hai cột dóng hàng.
- Có thể thêm sheet thống kê riêng, nhưng không thay đổi cấu trúc sheet `DONG_HANG`.
- Tên file: `<MA_TAC_PHAM>_parallel.xlsx`.

3.1. Các kiểu dóng hàng được chấp nhận

- `1–1`: một câu/đoạn Hán tương ứng một câu/đoạn Việt.
- `1–n`: một đơn vị Hán tương ứng nhiều câu Việt; gộp các câu Việt liên quan vào cùng một ô.
- `n–1`: nhiều câu Hán tương ứng một câu Việt; gộp các câu Hán liên quan vào cùng một ô.
- `n–m`: chỉ dùng khi bản dịch tái cấu trúc mạnh và không thể tách nhỏ hơn mà vẫn giữ đúng nghĩa.

Ưu tiên đơn vị nhỏ nhất có ý nghĩa đầy đủ. Không chia cơ học theo dấu câu nếu việc chia làm mất quan hệ dịch.

4. Quy trình thực hiện tổng thể

Bước 1 – Nhận đề tài và xác nhận phạm vi

Trước khi làm, nhóm phải xác nhận:
- Mã đề tài và tên tác phẩm.
- Quyển, tập, chương hoặc khoảng trang được giao.
- Nguồn Hán và nguồn Việt.
- Định dạng từng nguồn: ảnh, PDF Scan, PDF Text hoặc Text.

Không bắt đầu OCR hàng loạt nếu chưa chắc hai bản chứa cùng phạm vi nội dung.

Bước 2 – Kiểm kê nguồn

Lập bảng kiểm kê tối thiểu gồm:

Trường	Nội dung
Tên tài liệu	Tên đầy đủ
Ngôn ngữ	Hán hoặc Việt
Link nguồn	URL truy cập
Tên tệp	Tên file tải về
Số trang	Tổng số trang và trang nội dung
Định dạng	Ảnh/PDF Scan/PDF Text/Text
Phạm vi	Quyển/chương/trang
Ghi chú	Thiếu trang, mờ, trùng trang…

Kiểm tra nhanh đầu, giữa và cuối tài liệu để xác nhận đúng tác phẩm. Nếu hai bản khác cấu trúc, lập bảng ánh xạ quyển/chương trước khi OCR.

Lưu ý khi bản Hán và bản dịch Việt nằm trong cùng một quyển/file cần:

- Xác định bố cục: Kiểm tra cách sắp xếp: Hán trước – Việt sau, hai cột song song, hai trang đối diện hoặc xen kẽ từng đoạn.
- Tách riêng hai bản
  - Trích xuất bản Hán thành một tệp riêng.
  - Trích xuất bản Việt thành một tệp riêng.
  - Giữ lại mã trang và thứ tự xuất hiện để có thể đối chiếu lại với PDF.

Bước 3 – Sao lưu và đặt tên file

- Giữ nguyên một bản nguồn, không chỉnh sửa trực tiếp.
- Tên trang nên có số thứ tự cố định chiều dài, ví dụ `0001.png`, `0002.png`.
- Không dùng tên kiểu `final`, `final2`, `final_new`.
- Dùng phiên bản rõ ràng: `v01`, `v02`, ngày hoặc mã commit.
- Không đưa mật khẩu, cookie hay dữ liệu tài khoản vào thư mục bàn giao.

Bước 4 – OCR hoặc trích xuất text

Tuỳ thuộc vào nguồn tác phẩm:

- Định dạng PDF Scan hoặc ảnh: thực hiện OCR; Lưu riêng OCR thô và text đã sửa để có thể truy vết.
- Định dạng PDF Text/Text/doc/docx: thực hiện trích xuất text
- Nguồn trực tuyến: thực hiện crawl dữ liệu

Bước 5 – Làm sạch text

Thực hiện tối thiểu:

- Bỏ đầu trang, chân trang và các trang không thuộc nội dung chính.
- Ghép từ/câu bị ngắt do chuyển trang.
- Loại dòng trùng do OCR lặp vùng.
- Loại bỏ chú thích nằm ngoài nội dung chính, bao gồm chú thích ở chân trang, các chỉ mục chú thích chèn trong nội dung chính (như [1], (1) v.v..).
- Sửa ký tự rác và khoảng trắng bất thường.
- Chuẩn hóa dấu câu nhưng không thay đổi nghĩa.
- Giữ tên riêng, niên hiệu, con số và đơn vị đo theo nguồn.
- Bỏ qua các bảng biểu và tranh/ảnh nếu có.

Bước 6 – Tách câu

Đối với Hán văn:

- Dùng `。！？；` làm gợi ý, không coi là quy tắc tuyệt đối.
- Văn bản cổ có thể không có dấu câu hoặc dấu câu do người biên tập thêm.

Đối với tiếng Việt:

- Dùng `.?!;:` kết hợp cấu trúc ngữ nghĩa.
- Chú ý chữ viết tắt, số thứ tự và tên riêng có dấu chấm.
- Bản dịch có thể gộp hoặc diễn giải nhiều câu Hán.

Bước 7 – Đóng hàng

5. Gợi ý công cụ

Nhóm không bắt buộc dùng các công cụ dưới đây. Nhóm có thể đề xuất công cụ khác nếu thấy phù hợp.

5.1. Xử lý PDF và ảnh

- `pdfinfo`, `pdftotext`, `pdftoppm` (Poppler): đọc thông tin, trích text, tách ảnh.
- OCRmyPDF: thêm lớp OCR và chỉnh nghiêng PDF.
- ScanTailor Advanced: cắt trang, chỉnh nghiêng, xử lý lề.
- ImageMagick: chuyển đổi và xử lý ảnh hàng loạt.
- Adobe Acrobat, ABBYY FineReader hoặc công cụ tương đương nếu nhóm có quyền sử dụng.

5.2. OCR tiếng Việt

- Tesseract với mô hình tiếng Việt.
- PaddleOCR.
- Google Drive OCR/Google Lens.
- VietOCR.
- ABBYY FineReader hoặc Adobe Acrobat OCR.
- Sử dụng voting.

5.3. OCR Hán văn

- PaddleOCR với mô hình Chinese Traditional.
- Google Lens/Google Cloud Vision.
- Transkribus nếu mô hình phù hợp tài liệu.
- KanjiTomo hoặc công cụ nhận dạng chữ Hán hỗ trợ kiểm tra cục bộ.
- Mô hình OCR chuyên biệt do nhóm tự huấn luyện/đề xuất.
- Sử dụng voting.

OCR tự động chỉ tạo bản nháp; mọi kết quả cần được con người kiểm tra.

5.4. Biên tập và dóng hàng

- Microsoft Excel, LibreOffice Calc hoặc Google Sheets cho dữ liệu nhỏ.
- Visual Studio Code, Notepad++ hoặc Sublime Text cho TSV/Text.
- Hunalign, Bleualign, BertAlign, Vecalign…
- Python với `pandas`, `regex`, `openpyxl` hoặc thư viện NLP.
- Công cụ web/nội bộ do nhóm tự xây dựng.

6. Tiêu chí một cặp dóng hàng đúng

Một cặp được xem là đúng khi:

1. Hai vế nói về cùng nội dung.
2. Không bỏ mất ý quan trọng.
3. Không thêm nội dung thuộc câu/đoạn khác.
4. Tên riêng, chức danh, địa danh cơ bản tương ứng.
5. Thời gian, niên hiệu và con số tương ứng.
6. Ranh giới câu/đoạn hợp lý.
7. Không phải dòng tiêu đề, số trang hoặc OCR rác ghép nhầm.

Bản dịch không cần sát từng chữ; đánh giá dựa trên quan hệ dịch và phạm vi nội dung.

7. Phân loại lỗi

`OMISSION` – Thiếu nội dung

Vế Việt bỏ phần quan trọng của vế Hán hoặc một đoạn nguồn bị mất khỏi kết quả.

`ADDITION` – Thừa nội dung

Vế Việt chứa nội dung thuộc câu khác, chú thích không tương ứng hoặc phần thêm làm sai phạm vi cặp.

`MISSING` – Thiếu một vế hoặc thiếu cặp

Dòng không có Hán/Việt, hoặc đoạn tương ứng hoàn toàn không được đưa vào dữ liệu.

8. Công thức đánh giá chất lượng

```
Tỷ lệ lỗi = Số cặp lỗi / Số cặp được kiểm tra hợp lệ
```

Quy tắc nghiệm thu dự kiến:

- Tỷ lệ lỗi ≤ 30%: đạt ngưỡng nghiệm thu.
- Tỷ lệ lỗi > 30%: không đạt, phải sửa/làm lại.

Mục tiêu nội bộ nên là ≤ 20% để có biên an toàn. Việc đạt ngưỡng không có nghĩa được phép giữ lỗi đã phát hiện; mọi lỗi cụ thể trong mẫu phải được sửa và rà soát các lỗi tương tự trên toàn file.

9. Đề xuất phương pháp khác

Nhóm được phép đề xuất:

- Công cụ OCR khác.
- Mô hình tự huấn luyện.
- Thuật toán dóng hàng tự động/bán tự động.
- Giao diện hiệu đính riêng.
- Quy trình kiểm tra bổ sung.

Đề xuất phải nêu:

1. Lý do lựa chọn.
2. Dữ liệu đầu vào và đầu ra.
3. Cách kiểm chứng.
4. Rủi ro và phương án dự phòng.
5. Khả năng tái lập bởi người khác.